Mejora de sistemas de reconocimiento automático del habla mediante aprendizaje curricular basado en prosodia

Ariadna Frutos

Trabajo de investigación para el Máster en Tecnologías del Lenguaje

Dirigido por:

Juan Manuel Cigarrán (UNED)
Mireia Farrús (UB)

Contenidos

1 Introducción

2 Proceso experimental

3 Resultados

4 Conclusiones y trabajo futuro

1. Introducción

1.1 Reconocimiento automático del habla

1.2 Aprendizaje curricular

1.3 Prosodia y calidad de voz

1.4 Objetivos y metodología

1.1 Reconocimiento automático del habla

¿Qué?

Tecnología que permite a las máquinas convertir lenguaje hablado a texto escrito (transcripción)

En inglés: *Automatic Speech Recognition* (ASR)

¿Dónde?

Múltiples aplicaciones: Teleoperadores, asistentes virtuales domésticos, sistemas integrados en coches, domótica, subtitulación automática, dictado de informes, ayuda a personas con discapacidades, aplicaciones industriales....

¿Cómo?

Modelos end-to-end: Un solo modelo, basado en una red neuronal que mapea directamente las secuencias de características acústicas a secuencias de fonemas o palabras.

1.2 Aprendizaje curricular

¿Qué?

Técnica de entrenamiento de redes neuronales que consiste en organizar el **aprendizaje en etapas, empezando por los datos o tareas más "fáciles"**.

En inglés: *Curriculum Learning* (CL)

Ventajas

- Acelera el entrenamiento
- Aumenta la precisión

Retos

- Definir "fácil" y "difícil": **métrica de dificultad**
- Organizar el entrenamiento: **programación** o ***schedule***.

Ejemplo métrica de dificultad en ASR

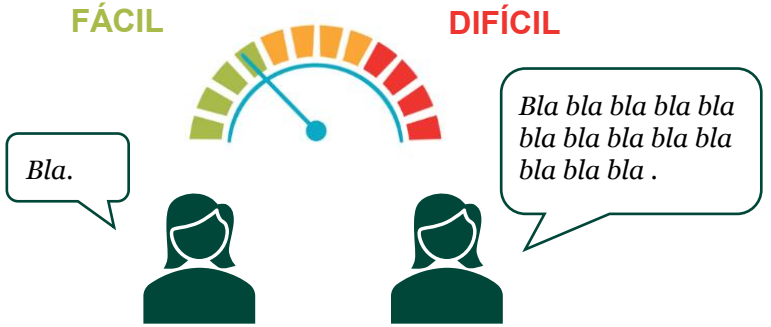

Longitud de los ejemplos

1.3 Prosodia

¿Qué?

Propiedades del habla que percibimos como *melodía* cuando escuchamos segmentos largos, como sílabas, palabras y frases.

¿Cómo?

Prosodia

- Tono o frecuencia fundamental
- Intensidad
- Ritmo

Calidad de voz

- Jitter
- Shimmer
- tasa harmónicos-ruido (HNN)

¿Para qué?

Personas

- Comprendemos mejor el habla cuando la entonación es natural.
- Los bebés aprenden antes el nivel prosódico que otros niveles lingüísticos.

Máquinas

- La velocidad, la frecuencia fundamental y el jitter se han relacionado con la precisión de sistemas ASR.
- La frecuencia fundamental y la sonoridad se utilizan en la herramienta de ASR Kaldi.
- El jitter y el shimmer resultan de ayuda en reconocimiento de hablantes, detección de hablantes, clasificación de género, detección de emociones.

Análsis del habla

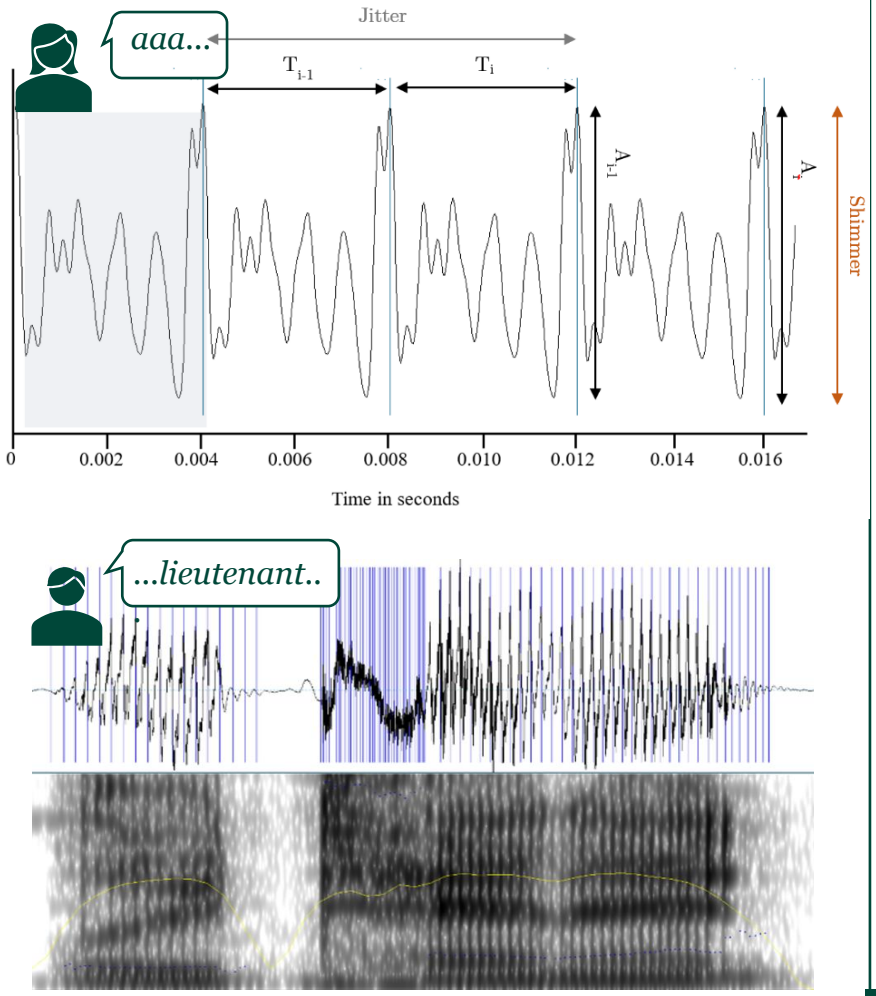

1.4 Objetivos y metodología

Hipótesis

i) Puede resultar más fácil para los sistemas ASR transcribir el habla cuando presenta ciertas características prosódicas.

ii) Estas características prosódicas pueden servir para definir estrategias de entrenamiento basadas en CL que mejoren el rendimiento de los sistemas ASR.

Objetivos

i) Relacionar características prosódicas con la capacidad de un sistema ASR de hacer buenas transcripciones.

ii) Comprobar si estrategias de CL basadas en estas características prosódicas pueden mejorar el rendimiento de los sistemas ASR.

Metodología

i) Selección de parámetros prosódicos: Hemos relacionado características prosódicas con número de errores realizados por un sistema ASR *state-of-the-art* pre-entrenado.

ii) A partir de los resultados anteriores, hemos definido una estrategia de CL y hemos entrenado un sistema ASR desde cero siguiendo esta estrategia.

2. Proceso experimental

2.1 Proceso experimental 1: selección de parámetros prosódicos

2.2 Proceso experimental 2: Entrenamiento con CL

2.3 Colecciones, modelos y herramientas

2.4 Parámetros prosódicos

2.5 Métricas

2.1 Proceso experimental 1: Selección de parámetros prosódicos

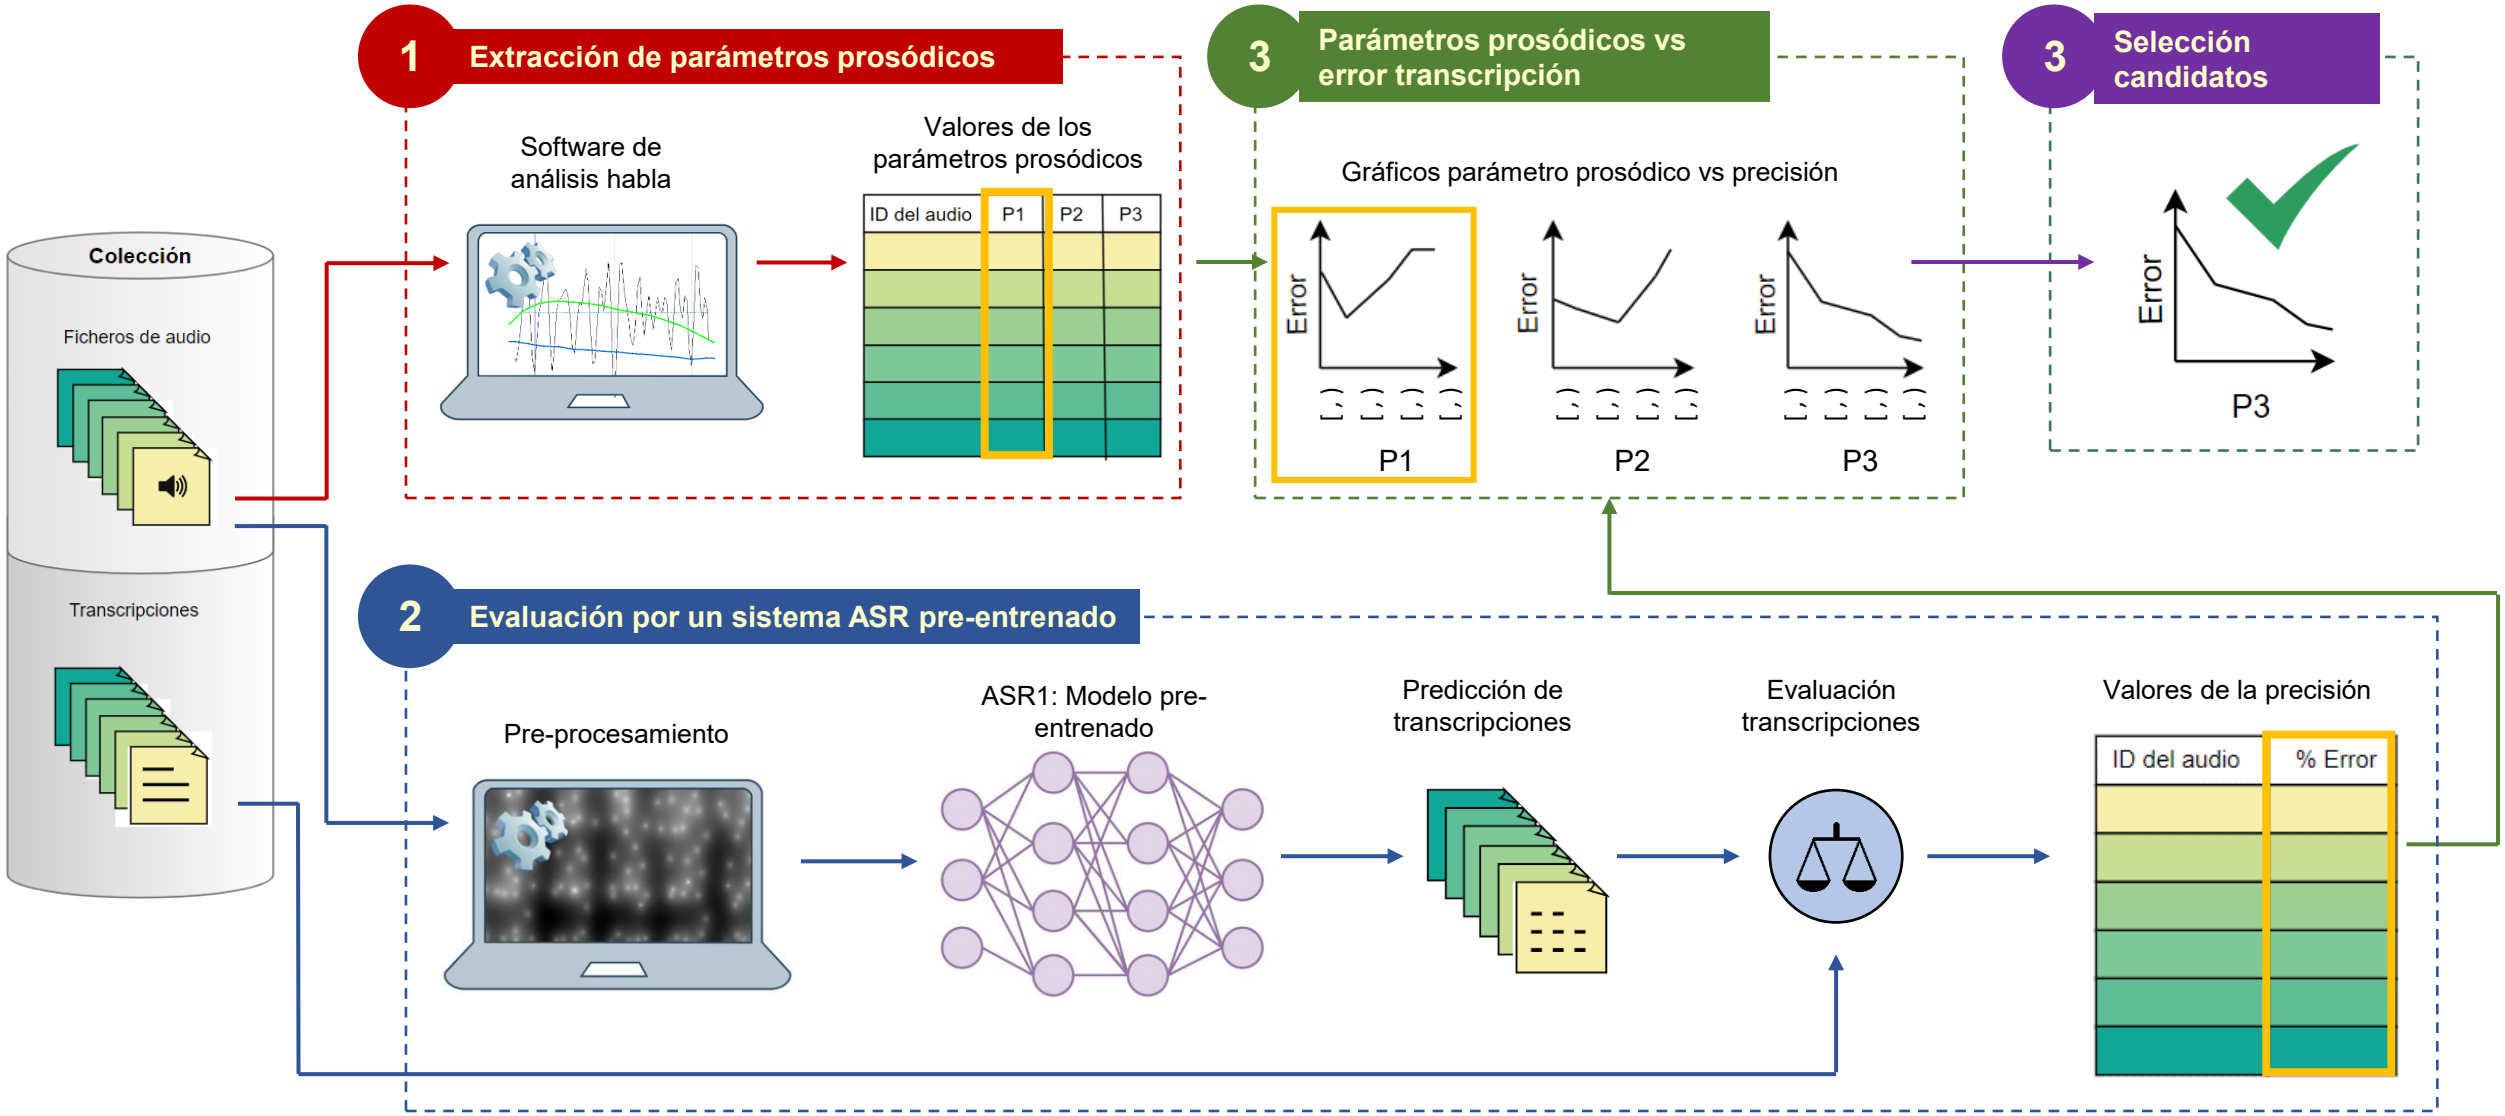

2.2 Proceso experimental 2: Entrenamiento con CL

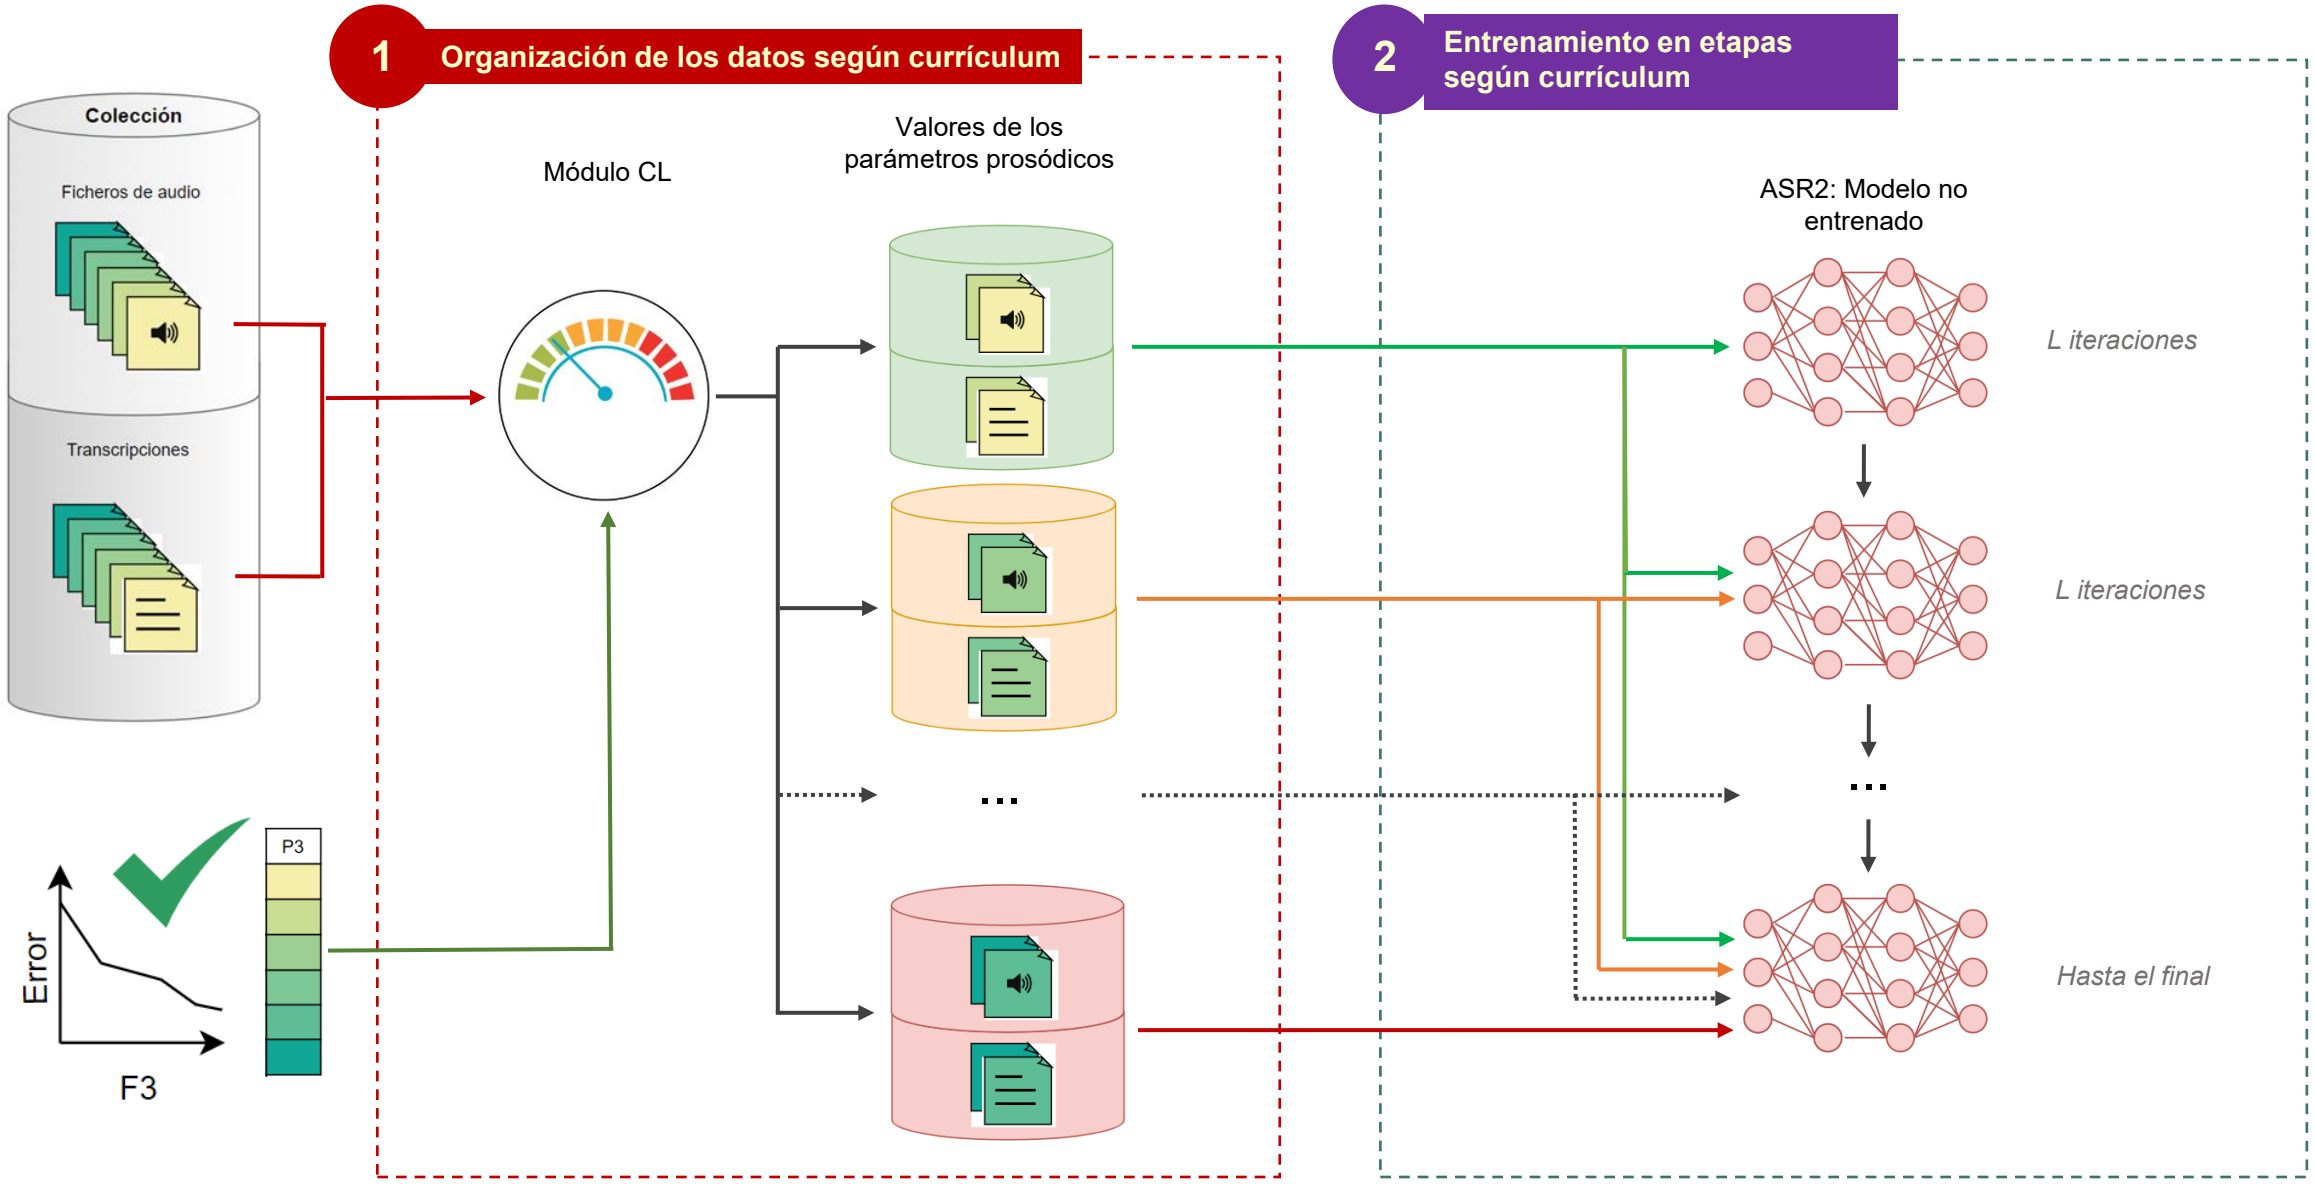

2.3 Colecciones, modelos y herramientas

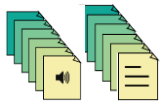

Colección: **LibriSpeach**

- Audios de LibriVox + textos de Gutenberg Project
- Entrenamiento: train-clean (100 h, 28.539 muestras)
- Validación: dev-clean (5.5 h, 2.703 muestras)

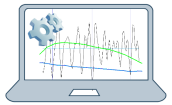

Análisis del habla: **Praat + Parselmouth**

- Praat: Programa de análisis del habla con interfície gráfica
- Parselmouth: Librería Python que permite realizar los cálculos de Praat de forma masiva.

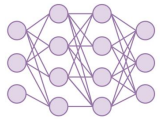

Modelo pre-entrenado ASR1

Hugging Face / Speechbrain

- Transformer
- Pre-entrenado con CommonVoice

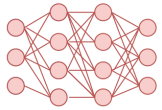

Modelo a entrenar ASR2: **Fairseq/ S2T**

- Transformer, 30M parámetros
- Entropía cruzada
- Optimizador Adam
- lr según raíz cuadrada inversa
- Sin/con warm-up
- FP16 / FP32

Módulo de CL: **Speacher**

- Entrada: listado original de ejemplos
- Salida: sublistados de ejemplos y carpetas con las muestras, clasificados según el currículo seleccionado
- Desarrollado en la UPF

2.4 Parámetros prosódicos

4 parámetros relacionados con la **frecuencia fundamental**, f0:

- Frecuencia fundamental media (mean_f0),
- Desviación estándar de la frecuencia fundamental (stdev_f0)
- Variación de la frecuencia fundamental o **contorno de tono**, en valor absoluto (abs(mean_delta_f0))
- Desviación estándar de la variación de la frecuencia fundamental (stdev_delta_f0)

2 parámetros relacionados con la **intensidad**:

- Variación de la intensidad o **contorno de intensidad**, en valor absoluto (abs(mean_delta_intensity)
- Desviación estándar de la variación de la frecuencia fundamental (stdev_delta_intensity)

12 parámetros relacionados con la **calidad de la voz** (1+5+6)

- Tasa harmónicos-ruido (HNR)
- Jittter (local_absolute_jitter, local_jitter, rap_jitter, ppq5_jitter, ddp_jitter)
- Shimmer (localdb_shimmer, local_shimmer, appq3_shimmer, appq5_ shimmer, appq11_ shimmer, dda_shimmer)

"Lieutenant thomas is badly wounded in here and we can't move him"

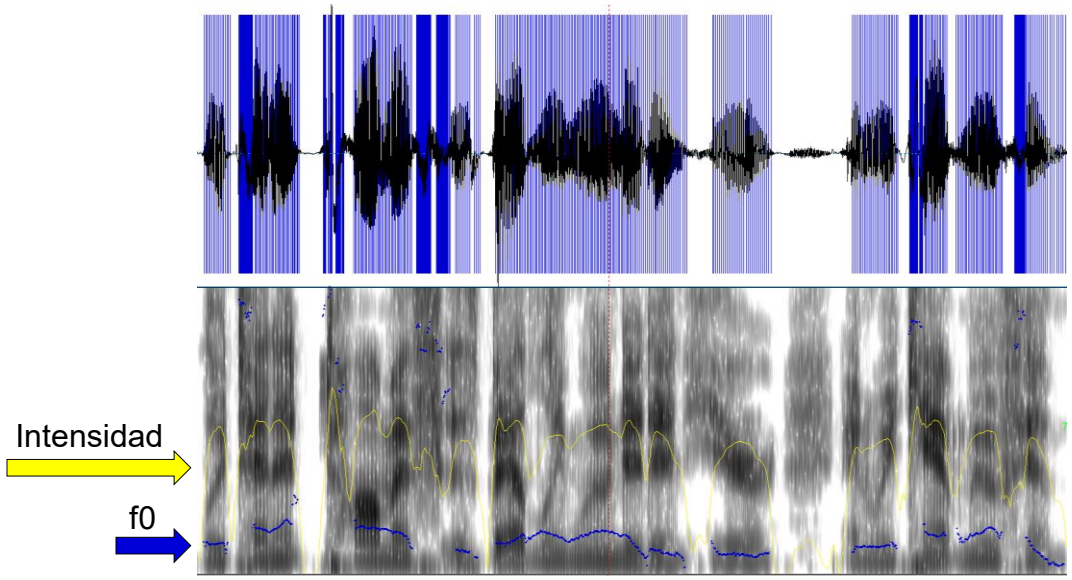

2.5 Métricas

Tasa de errores en palabras (Word Error Rate, WER)

$$\text{WER} = \frac{S + B + I}{N}$$

- S: palabras sustituidas
- B: Palabras borradas
- I: Palabras insertadas
- N: Número total de palabras

Precisión

$$\text{Precisión} = 1 - \text{WER}$$

Comparativa

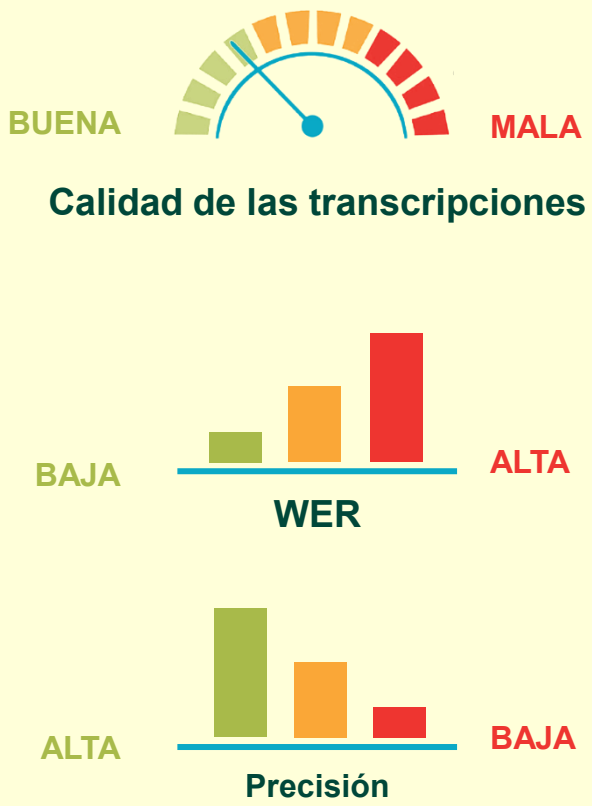

3. Resultados

3.1 Proceso experimental 1

- Relación WER vs parámetros prosódicos
- Selección métrica de dificultad y programación

3.2 Proceso experimental 2

- Baseline
- CL basado en contorno de tono, sin warm-up
- CL basado en contorno de tono, con warm-up

3.1 Proceso experimental 1: Relación parámetros prosódicos vs tasa de error

Para cada parámetro prosódico:

1. Se ha realizado una partición de la colección en *N* intervalos según cuantiles basados en el valor del parámetro considerado.
2. Se ha calculado la tasa de error (WER) media de cada intervalo.
3. Se han representado los puntos (intervalo, WER media).

EJEMPLO: Partición en cuantiles según el ***contorno de tono*** *(abs(mean_delta_f0))*

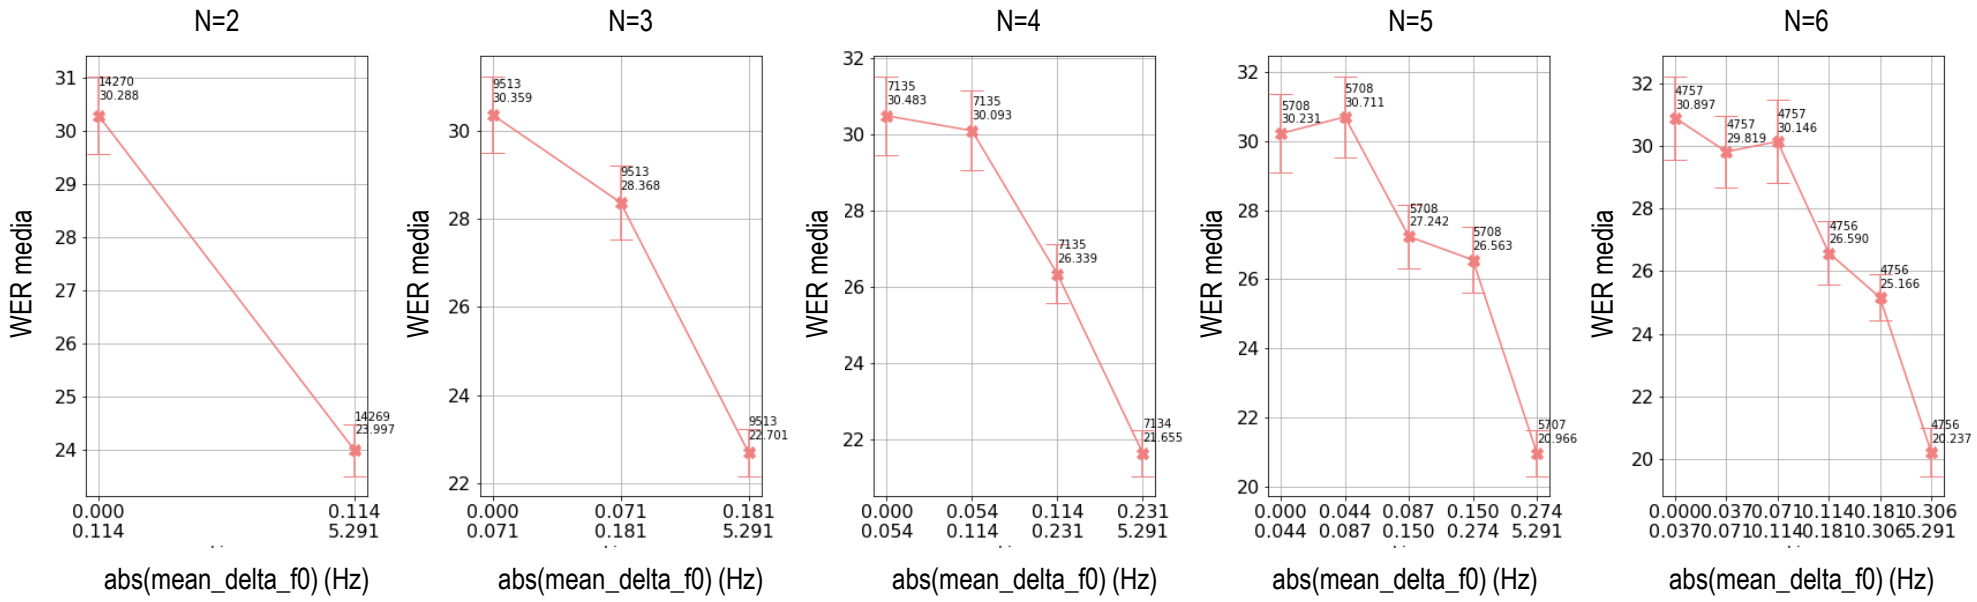

Comparativa

Contorno de tono ***mayor***

WER (promedio) ***menor***

Dificultad ***menor***

3.1 Proceso experimental 1: Selección métrica de dificultad y programación

Resultados relevantes:

Partición en cuartiles según el ***contorno de tono*** *(abs(mean_delta_f0))*

Contorno de tono ***mayor***

WER (promedio) ***menor***

Dificultad ***menor***

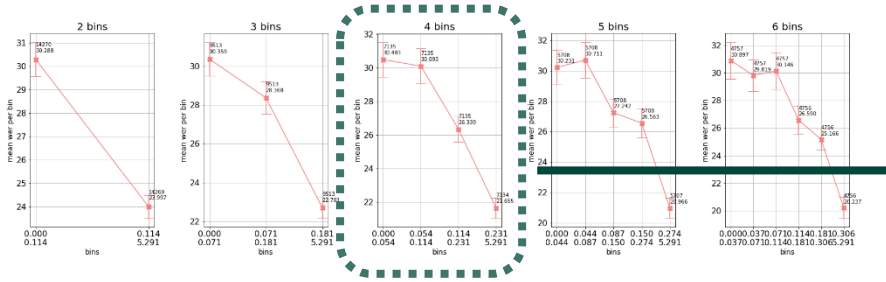

Partición en cuartiles según el ***contorno de intensidad*** *(abs(mean_delta_intensity))*

Contorno de intensidad ***mayor***

WER (promedio) ***menor***

Dificultad ***menor***

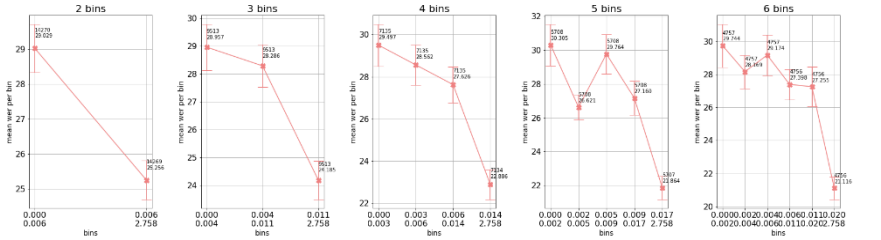

Partición en cuartiles según la ***desviación estándar de f0*** *(stdev_f0)*

Desviación f0 ***mayor***

WER (promedio) ***mayor***

Dificultad ***mayor***

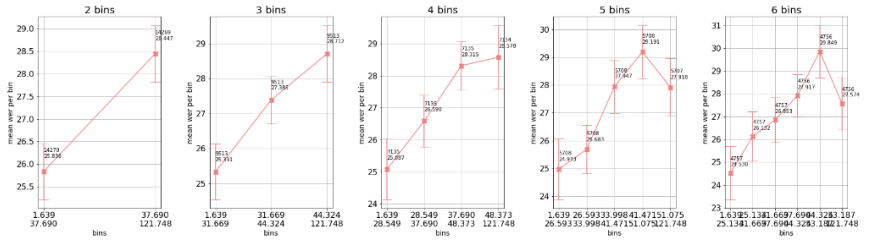

ESTRATEGIA DE CURRICULUM LEARNING

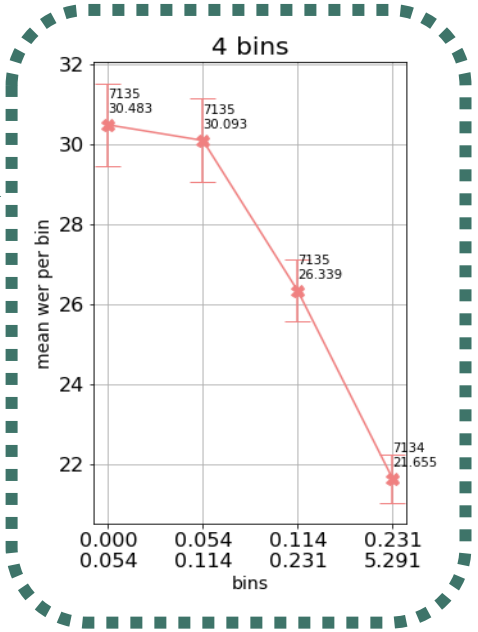

Métrica de dificultad:

Contorno de tono (abs(mean_delta_f0))

Programación:

Entrenamiento en N=4 etapas

Número de iteraciones en las 3 primeras etapas:

Entrenamiento sin warm-up: l=10.000

Entrenamiento con warm-up: l=1.000

Número total de iteraciones

Entrenamiento sin warm-up: L=300.000

Entrenamiento con warm-up: L=30.000

Partición de la colección

Nombre	Número de muestras	Valores de abs(mean_delta_f0) (Hz)
Subconjunto 1	7135	[0.000, 0.054)
Subconjunto 2	7135	[0.054, 0.114)
Subconjunto 3	7135	[0.114, 0.231)
Subconjunto 4	7134	[0.231, 5.291]

3.2 Proceso experimental 2: Baseline

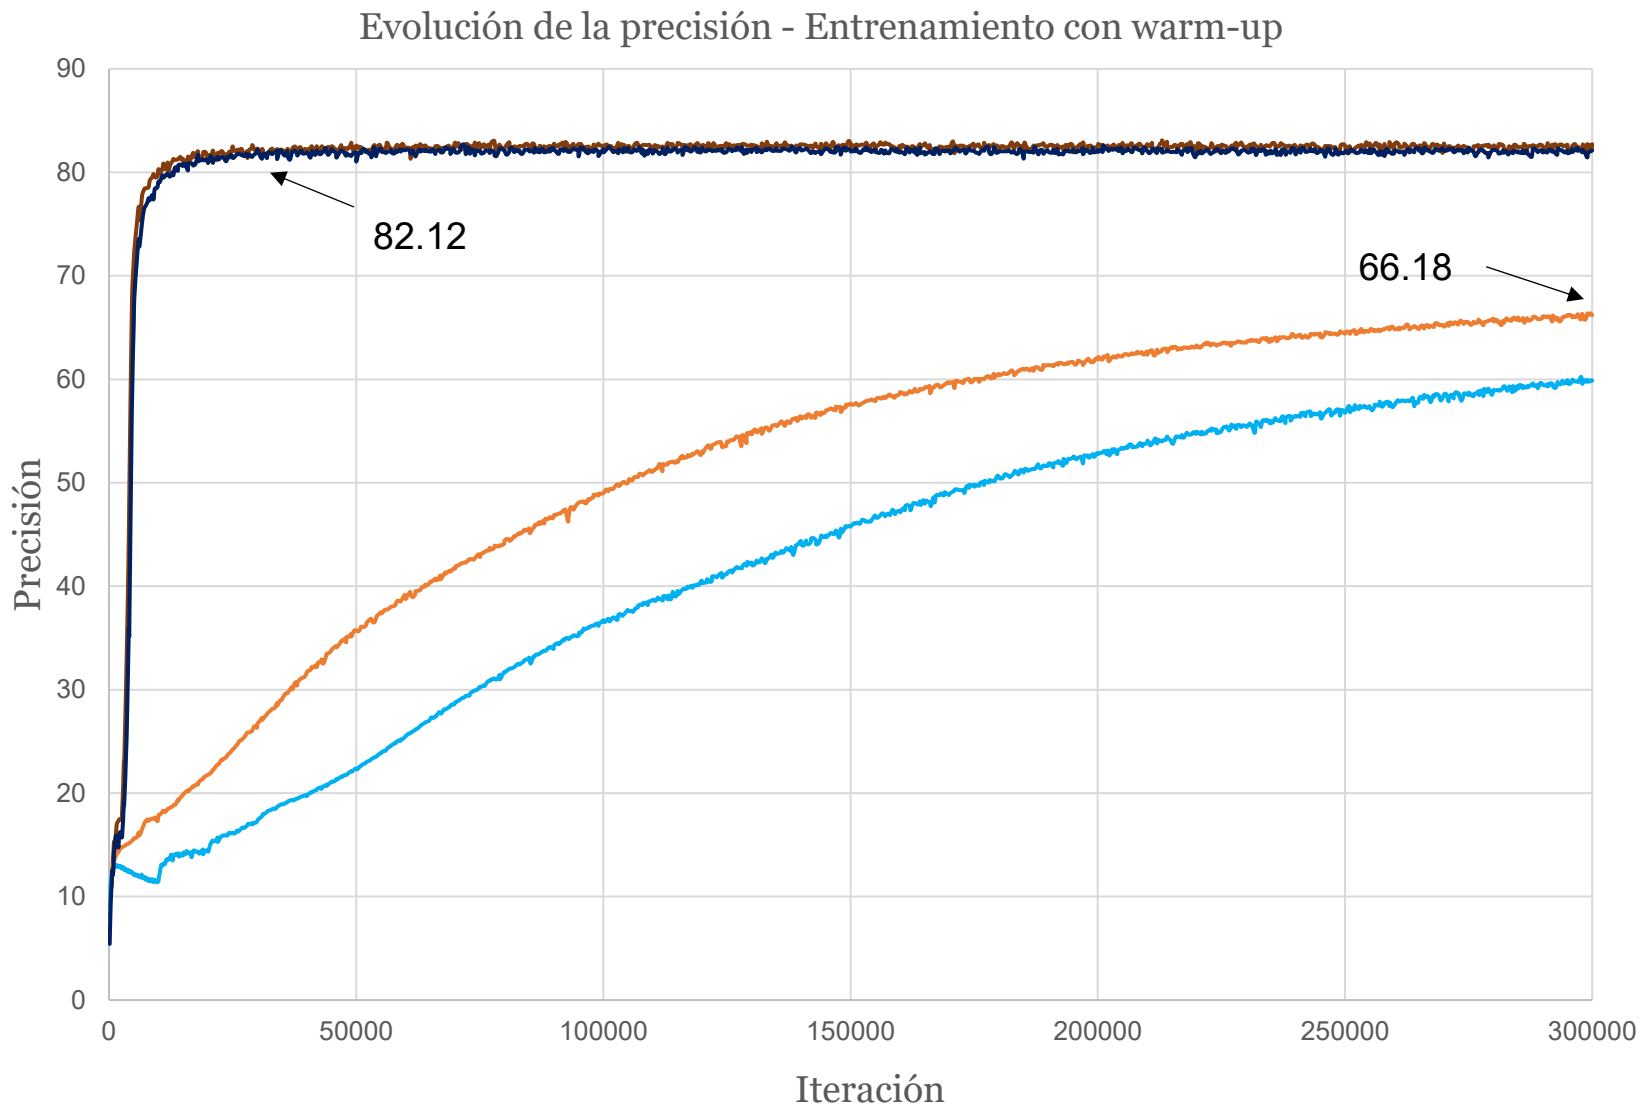

Baseline sin warm-up

Entrenamiento con la colección entera desde el inicio, introduciendo paquetes (*batches*) aleatoriamente.

Baseline con warm-up

Entrenamiento con la colección entera desde el inicio, introduciendo paquetes (*batches*) aleatoriamente. , con una etapa de warm-up de 10.000 iteraciones.

Hipótesis nula sin warm-up

Hipótesis nula con warm-up

Entrenamiento en N=4 etapas: en cada etapa se añade un subconjunto con 25% de las muestras, como en CL, pero las muestras se seleccionan aleatoriamente.

3.2 Proceso experimental 2: CL basado en contorno de tono, sin warm-up

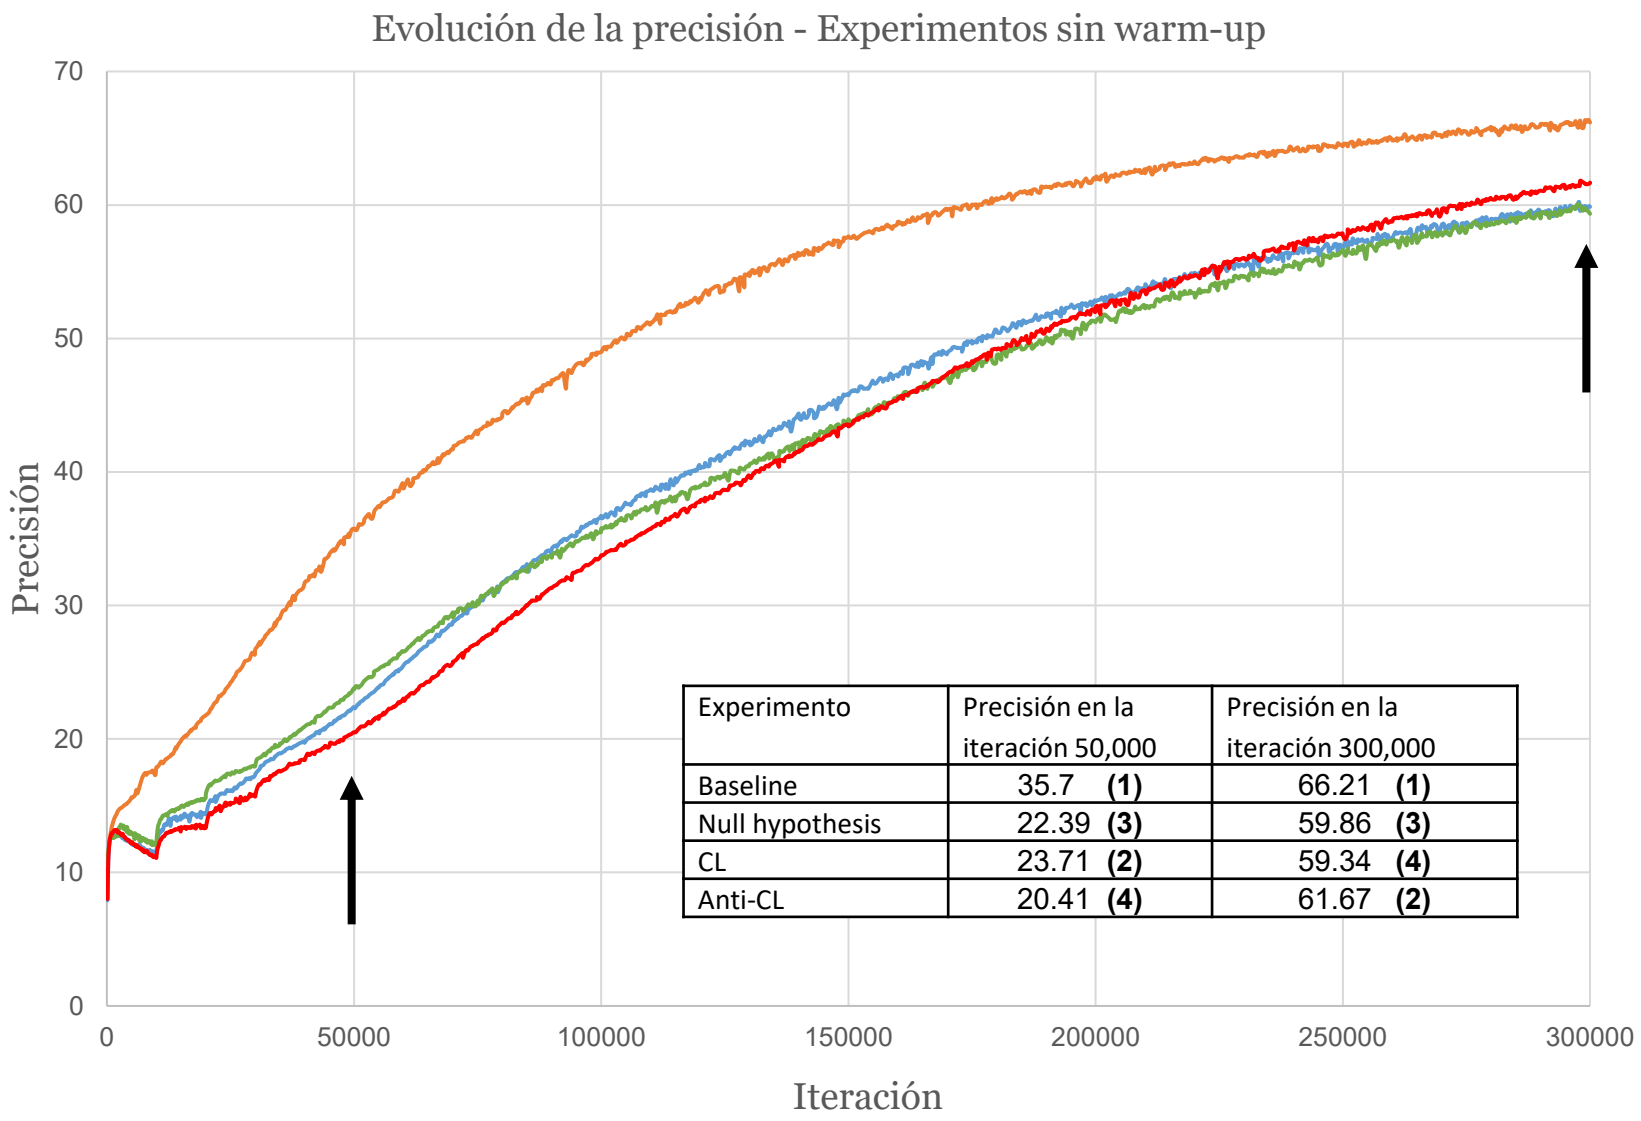

Experimento	Precisión en la iteración 50,000	Precisión en la iteración 300,000
Baseline	35.7 **(1)**	66.21 **(1)**
Null hypothesis	22.39 **(3)**	59.86 **(3)**
CL	23.71 **(2)**	59.34 **(4)**
Anti-CL	20.41 **(4)**	61.67 **(2)**

Baseline

Entrenamiento con la colección entera desde el inicio, introduciendo batches aleatoriamente.

Hipótesis nula

Entrenamiento en N=4 etapas: en cada etapa se añade un subconjunto con 25% de las muestras, seleccionadas aleatoriamente.

CL

Entrenamiento en N=4 etapas: en cada etapa se añade un subconcjunto con el 25% de las muestras, en orden DESCENDIENTE del contorno de tono.

Anti-CL

Entrenamiento en N=4 etapas, utilizando los mismos subconjuntos que en el caso CL, pero introducidos en orden inverso, i.e orden ASCENDIENTE del contorno de tono.

3.2 Proceso experimental 2: CL basado en contorno de tono, con warm-up

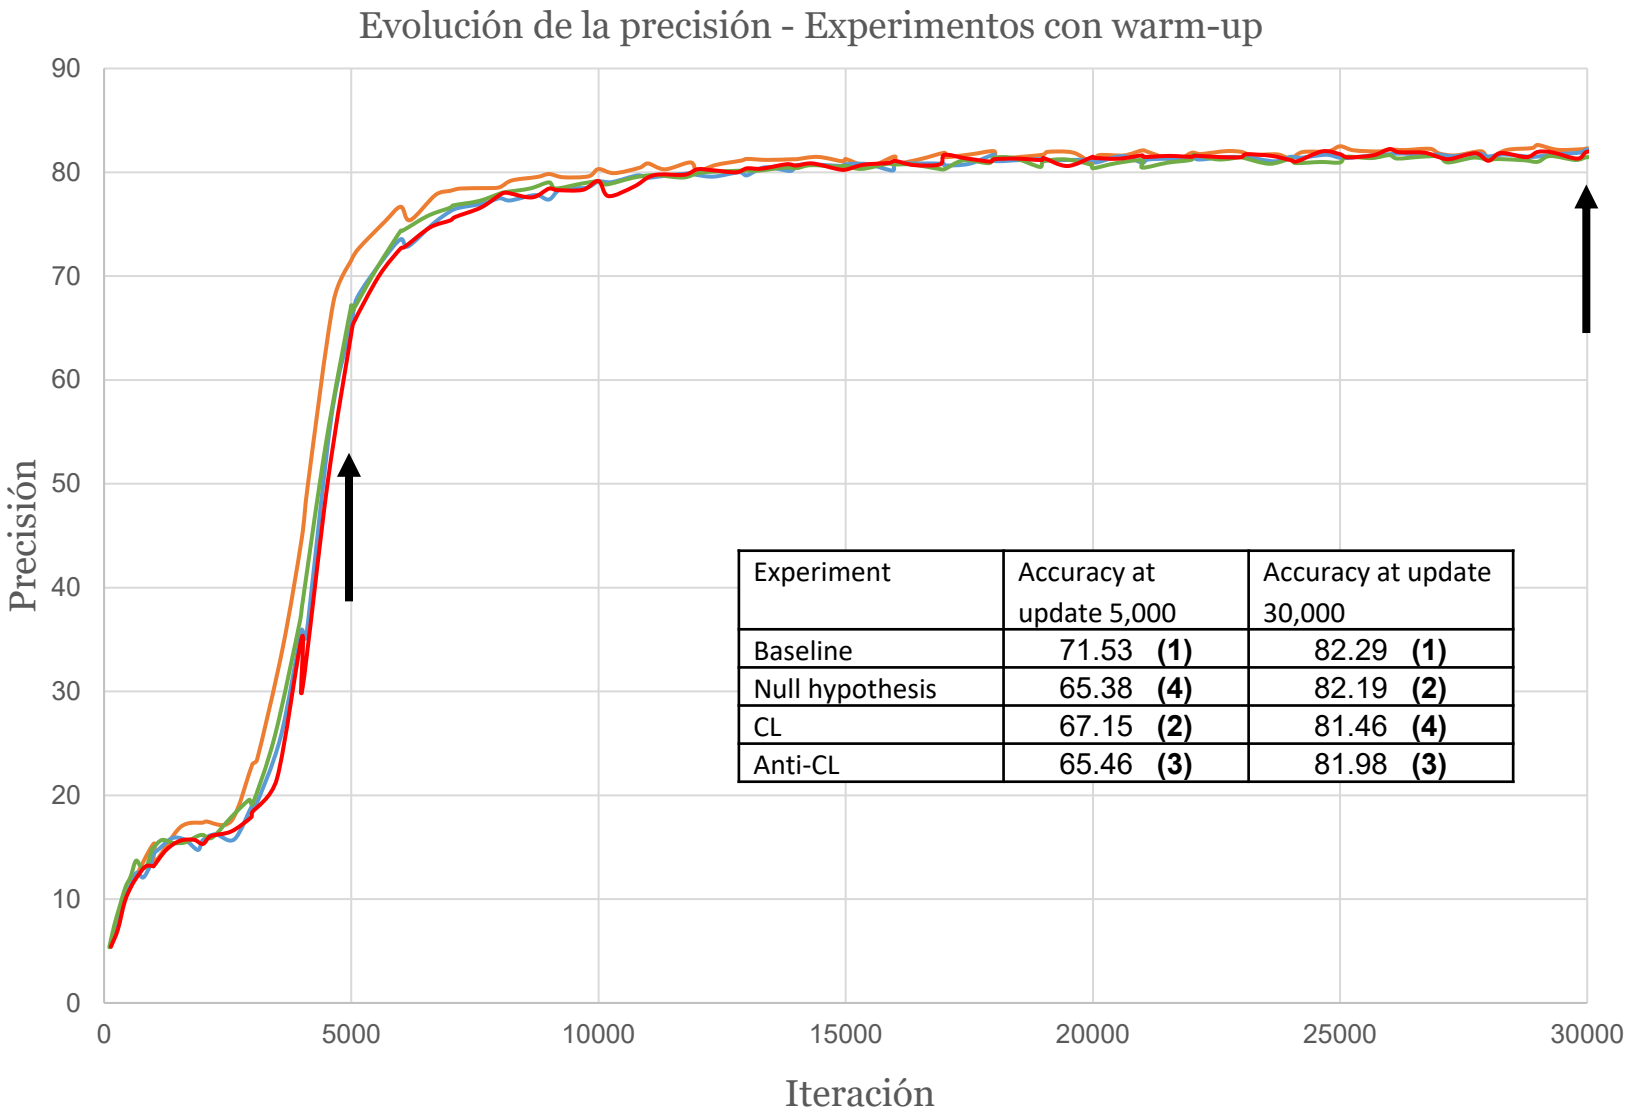

Experiment	Accuracy at update 5,000	Accuracy at update 30,000
Baseline	71.53 **(1)**	82.29 **(1)**
Null hypothesis	65.38 **(4)**	82.19 **(2)**
CL	67.15 **(2)**	81.46 **(4)**
Anti-CL	65.46 **(3)**	81.98 **(3)**

Baseline

Hipótesis nula

CL

Anti-CL

4. Conclusiones y trabajo futuro

4.1 Conclusiones

4.2 Trabajo futuro

4. Conclusiones

Prosodia en ASR

Relación parámetros prosódicos vs errores de transcripción de un sistema ASR pre-entrenado

- Las declaraciones con mayor contorno de tono (abs(mean_delta_f0) o de intensidad (abs(mean_delta_intensity)) son, en promedio, más fáciles de transcribir.
- Las declaraciones con mayor desviación estándar de la frecuencia fundamental (stdev_f0) son más difíciles de transcribir. !?
- El resto de parámetros prosódicos analizados no muestra una relación clara con el número de errores.

Curriculum learning con prosodia

Entrenamiento de un sistema ASR por etapas, empezando con los ejemplos con contorno de tono mayor (más “fáciles”)

- La introducción de datos empezando por los ejemplos con mayor contorno de tono tiene un efecto positivo al principio del entrenamiento, pero no al final.
- Este efecto positivo no es suficiente para compensar el efecto negativo provocado por el entrenamiento por etapas.

4.1 Trabajo futuro

Prosodia en ASR

- Estudiar detalladamente la relación de la WER con el parámetro stdev_f0
- Analizar la relación de la WER con la modulación en términos de la frecuencia fundamental y la intensidad, medida como mean(abs_delta_f0) y mean(abs_delta_intensity) en vez de de abs(mean_delta_f0) y abs(mean_delta_intensity)

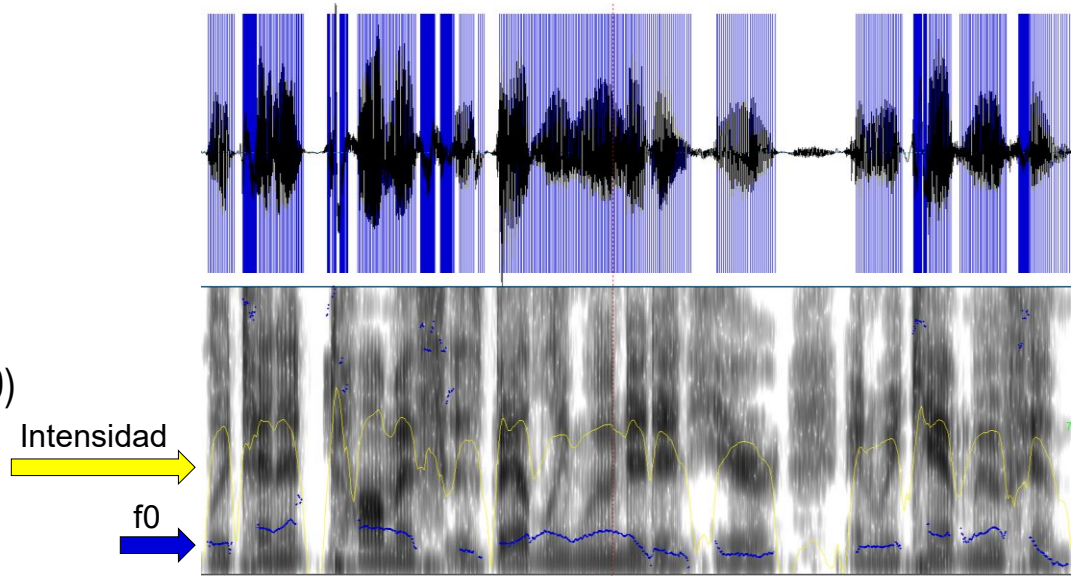

Curriculum learning con prosodia

- Ampliar el número de muestras en las primeras etapas
  - Reducir el número de etapas
  - Ampliar la colección
- Probar métricas resultantes de combinar parámetros prosódicos
- Probar programaciones con un número menor o mayor de iteraciones.
- Probar el efecto de CL basado en prosodia con otros modelos (RNN, GRU, LSTM)
  - El aprendizaje puede ser distinto
  - No solapamiento de efecto con warm-up

Muchas gracias